

Геометрия облака токенов

что меряет размерность на разных масштабах

Отчёт по сессии, 2026-09-07

Считано на 120 человеческих текстах COLING, ModernBERT-base, последний скрытый слой, $L = 201$ токен — 72 000 рёбер MST.

Главный вывод одной фразой:

Облако — тонкая оболочка, на которой каждый тип токена занимает ячейку примерно постоянного размера. Вся геометрия MST решается одним вопросом: есть ли у токена второй экземпляр в выборке. Есть — он и ближайший сосед, ребро короткое, это мелкая полоса. Нет — ближайшим оказывается чужой, ребро длинное, это крупная.

Содержание

- 1 Сток внимания: артефакт энкодера внутри каждого измерения
- 2 Состав рёбер: фазовый переход на 40-м перцентиле
- 3 Ось, которая всё решает, — двойник, а не частота
- 4 Хапаксы не с краю облака, а в пустоте
- 5 Ячейки и каркас: две геометрии в одном облаке
- 5a Те же ячейки на реальных данных
- 5b То же со всеми классами токенов
- 6 Перемешивание слов и синтетический контроль
- 7 Что закрыто, что осталось

1. Сток внимания

2.2% токенов — точечная масса, которой в тексте нет

В облаке ModernBERT сидит группа из 2.24% токенов с нормой 26.3 против 36–40 у всех остальных. Взаимный косинус внутри группы 0.987, среднее взаимное расстояние 4.1 против 30–33. Направление одно и то же во всех текстах: косинус члена с центром группы 0.993, у обычного токена 0.233.

Группа есть в каждом тексте без исключения, 6–28 штук, равномерно по документу, и состоит почти целиком из Ġthe (41%), . (28%), Ġto (10%), , (6%). Это свойство энкодера, а не текста.


Она даёт оба конца распределения рёбер сразу: 18% самых коротких 10% (длина 0.10 от средней) и 4.9% самых длинных 10% — перемычку, которой MST подключает массу к облаку.

Удаление стока, 40 текстов, 6 зёрен, два независимых прогона:

крупная	16.83	-> 18.93	+12.4%	(повтор +11.5%)
мелкая	3.44	-> 3.98	+15.3%	(повтор +14.9%)
средняя	13.61	-> 14.31	+5.0%	(повтор +4.1%)

Это две трети порога детектора (20%), сидящие внутри каждого измерения. Но с межтекстовым разбросом доля стоков не коррелирует ($r = -0.08 / -0.11 / +0.04$) — постоянный сдвиг уровня, а не источник различий. Убирать стоит по умолчанию.

Оговорка: «сток внимания» — интерпретация. Измерена геометрия; веса внимания не смотрели, и норма здесь малая, тогда как в литературе у стоков обычно большая.



t-SNE облака: слева по классу токена, в центре по однократности, справа по норме. Сток — чёрный остров внизу слева. [token_geometry.py, sink_cluster.py]

2. Состав рёбер по масштабу

распределение длин двухфазно, переход на 40-м перцентиле


Рёбра MST каждого текста отсортированы по длине и разрезаны на 20 равных бинов; каждое ребро попадает ровно в одну ячейку таксономии, так что бин суммируется в 100%.

Ниже 40-го перцентиле — почти только повторы одного и того же токена, выше — почти только разные. Доля «= служебное» падает 54% → 12.7% → 3.0% на бинах 25–30%, 40–45%, 50–55%. Разных смысловых слов среди 10% самых коротких рёбер ноль.

Полоса — это диапазон q, то есть набор перцентильных срезов. В переводе на состав:

	один токен	служ./пункт.	два смысловых	>=1 нарах
мелкая (0-40%)	86.9%	66.9%	2.4%	3.5%
средняя (30-100%)	6.6%	32.5%	41.0%	63.2%
крупная (50-100%)	1.4%	29.8%	35.9%	66.2%

Мелкая и крупная не имеют общих ячеек — и на 626 текстах их отклонения коррелируют всего на 0.22, тогда как средняя с крупной на 0.68. Композиция предсказала корреляции.



Состав рёбер по 5%-бинам длины, сверху отмечены окна трёх полос. [edge_taxonomy.py, band_composition.py]

3. Решает двойник, а не частота

корпусный ранг не разделяет ничего, кратность — всё




Таксономия делила смысловые слова по корпусной частоте, и две половины оказались неразличимы: норма 36.5 против 36.3, расстояния 29.8 против 30.0. Разрез, который ничего не разделяет, — не разрез.

Разделяет другое. Р(вершина — лист на длинном черешке) при базовом уровне 12.0%:

встречается один раз в выборке	24.9%	против	0.4%	59x
hарах в документе	23.6%	против	6.4%	3.7x
редкий в корпусе (ранг > 1000)	16.6%	против	10.3%	1.6x
смысловое редкое	14.0%	против	11.8%	1.2x

Из токенов, у которых двойник в выборке есть, длинными листьями становятся 0.4%. Перекрёст показывает, что корпусная редкость — не мягкая версия однократности, а другой признак: среди hарах она вероятность понижает (26.3% → 21.3%).

Заодно исправлена ошибка в отчёте: градиент «реже → короче вектор» ($r = -0.70$) почти целиком межклассовый. Внутри служебных и пунктуации -0.50 , внутри смысловых -0.11 .



Слева: распределение самого длинного ребра вершины по классу — кривые двух половин смысловых лежат друг на друге. В центре: то же по однократности, распределение бимодально. [leaf_class.py]

4. Хапаксы не с краю облака

не удалённость, а локальная пустота

Напрашивалась картинка «облако, из которого торчат хапаксы». Измерение на 11 779 вершинах её опровергает:

	до центра	до ближайшего	до всех
повторяется	23.08	15.32	32.79
hарах	22.55	23.63	32.30
Коэн d	-0.18	+1.81	-0.20



По радиусу хапаксы сидят там же, где все, даже чуть ближе к центру. Отличается только ближайший сосед. Это разница между «далеко от всех» и «рядом никого», и у нас второе — поэтому проекция облака в 2D этого не покажет никогда, а дерево показывает: дерево строится по ближайшим соседям.

Контроль на подмену: служебные слова повторяются по необходимости, смысловые часто однократны, так что «тело против хапаксов» могло быть «служебные против смысловых». Не могло: на одних смысловых словах эффект вдвое сильнее, $d = +2.80$, и среди длинных листьев 98.2% хапаксы при базовом уровне 52.8%.

Только смысловые слова: служебные, пунктуация и сток убраны.
Хапаксы не с краю облака — они внутри него, но вокруг каждого пусто.
Поэтому в дереве они листья на длинных черешках

- повторяется в тексте
- встречается один раз
- сток внимания
- длинное ребро
- короткое ребро

до центра облака — одинаково ($d = -0.16$),
до ближайшего — врозь ($d = +2.80$)



Текст 50, 201 токенов. Хапаксы — 44% вершин, но 85% длинных рёбер против 48% коротких.
По 112 текстам, только смысловые: длинный лист — хапакс в 98.2% случаев при базовом уровне 52.8%; $P(\text{длинный лист} | \text{hарах}) = 23.4\%$ против 0.5% у повторяющихся.
Раскладка Kamada-Kawai по метрике дерева: длины на бумаге приблизительные. Утверждение держится не на рисунке, а на врезке и на leaf_class.py.

Только смысловые слова: служебные, пунктуация и сток убраны. Красные — однократные. Врезка несёт само утверждение. [hapa_picture.py]

5. Ячейки и каркас

две геометрии в одном облаке


Каждый тип токена занимает ячейку, и ячейки не перекрываются. «Зазор» — расстояние до ближайшего чужого центра, делённое на сумму двух радиусов; больше единицы означает отсутствие перекрытия, и так в 98–100% текстов.

	радиус	центры	зазор
смысловые	0.232	0.864	1.64
служебные	0.279	0.811	1.26
пунктуация	0.257	0.871	1.49
подслова	0.213	0.928	2.04

Центры рассеяны с обычной плотностью (0.86 при средней парной 1.0) — структура возникает не из их расположения, а из того, что ячейка вчетверо меньше разноса.

qPND на облаке центров против обычного облака: крупная 20.0 → 24.5, средняя 16.0 → 24.3, мелкая 4.2 → 17.4. На каркасе три полосы сходятся к 24–25. Вся разница между полосами создаётся внутриячеечной структурой; упаковка внутри ячеек даёт $d \approx 6.2$.

У смысловых слов размер ячейки не зависит от числа экземпляров ($k^{+0.02}$), у служебных растёт ($k^{+0.19}$): смысловое слово повторяется в той же роли, служебное — в разных окружениях.



Пропорции измеренные: радиус ячейки 0.232, до ближайшего чужого центра 0.789, зазор 1.70 радиусов (круг нарисован в 1.5 радиуса); одиночек к ячейкам 3:1. Справа ячейки раздуты на 17%, центры не сдвинуты. Расположение выдуманно, счёт уменьшен для читаемости, настоящее облако ~24-мерно — на плоскости те же пропорции выглядят теснее, чем есть. Это схема, а не проекция.

Схема с измеренными пропорциями: радиус ячейки, разнос центров и зазор взяты из данных, расположение выдуманно. Настоящее облако ~24-мерно, на плоскости те же пропорции выглядят теснее, чем есть.

[frame_schematic.py]

5а. Те же ячейки на реальных данных

ничего не выдумано, но есть проекция

Схема выше показывает устройство, но её положения нарисованы. Здесь наоборот: настоящие векторы одного текста, каждый смысловой тип с двумя и более вхождениями своим цветом, центр ячейки — крестом, спицы показывают принадлежность, однократные слова серым.


Проекция выбиралась по измерению, а не по вкусу. Сначала взяли метрический MDS: он лучше держит глобальные расстояния (0.71 против 0.56), но рвёт сами ячейки — доля своих среди $k-1$ ближайших соседей падает с 97% в настоящем пространстве до 45% на рисунке. У ячейки из двух-трёх точек нет внутренней структуры, которую MDS мог бы сохранить.

t-SNE оптимизирует ровно соседства и потому держит ячейки целыми: 98% против 97% в настоящем пространстве, ближайший сосед — свой тип в 100% случаев. Плата в другом: он преувеличивает разрывы между группами.

	расстояния	ячейка цела	сосед свой
настоящее (768D)	-	97%	99%
MDS	0.71	45%	74%
t-SNE, перплексия 30	0.56	98%	100%

Поэтому по картинке читается одно и не читается другое. Читается: ячейки существуют, компактны, у каждой свой центр, а однократные слова заполняют пространство между ними, а не окаймляют облако снаружи — та же вещь, что измерена в разделе 4. Не читается: насколько ячейки разнесены и какая из них рыхлее. Разнесённость держится на числах раздела 5 (зазор 1.64 радиуса), а не на этом рисунке.

Ячейки смысловых слов ($k \geq 2$), текст 50: 26 типов, центр — крестом, спицы — принадлежность ячейке



t-SNE по настоящим расстояниям, перплексия 30. Ячейки держатся: свой тип среди $k-1$ ближайших соседей в 97% случаев в настоящем пространстве и 98% на рисунке; ближайший сосед свой — 99% и 100%.

Чего по картинке читать нельзя: насколько ячейки разнесены (общие расстояния переданы на 0.56 — t-SNE преувеличивает разрывы) и какая ячейка рыхлее (радиус +0.39). Разнесённость держится на числах: зазор 1.64 радиуса, раздел 5. Однократные слова — это ячейки из одной точки: своего центра у них нет, ближайший сосед всегда чужой.

26 типов с $k \geq 2$ и 40 однократных слов одного текста, 216 точек. Пары остаются парами, крупные ячейки — звёздами. [cells_projection.py]

56. То же со всеми классами токенов

цвет — тип токена, знак — класс

Та же процедура, но без отбора по классу: смысловые кружками, служебные квадратами, пунктуация треугольниками, под слова ромбами, сток звёздочками. Цвет по-прежнему означает тип токена, класс читается поверх цвета.

Откуда данные. Один документ COLING — человеческая часть, источник m4gt, подкорпус wikihow, английский, 1185 слов, id 6aafb4ca. Взят целиком, а не подвыборкой на $L = 201$: оценщику нужна фиксированная выборка, картинке — все вхождения. 1379 токенов после удаления [CLS] и [SEP]. Векторы — последний скрытый слой ModernBERT-base, ненормированные, те же, на которых считается qPND.

Как отфильтрован сток. Направление стока оценено на других текстах (документы 300–339 того же корпуса) как среднее направление токенов с нормой ниже 30 — 480 токенов. Точка этого текста считается стоком, если косинус с этим направлением больше 0.8 и норма меньше 30. Таких оказалось 31 из 1379 (2.2%), их норма 26.4 против 38.0 у остальных, и это точка (20 раз), Ġthe (8), Ġto (2), Ġand (1).


Сток сведён в одну ячейку, а не разложен по токенам: иначе стоковые Ġthe попадали бы в ячейку обычных Ġthe и растягивали её спицами через весь лист. Геометрически сток — один объект, независимо от того, какой это токен.

Что отображено. Типов с $k \geq 2$ в тексте 160; взяты 40 самых частых — 732 точки, плюс 45 случайных однократных токенов из 312, итого 777. Состав текста по классам: служебных 611, смысловых редких 297, смысловых частых 226, пунктуации 144, подслов 70, стоков 31.

Проекция: t-SNE по матрице настоящих расстояний (metric=precomputed), перплексия 30, случайная инициализация, зерно 0. Верность: ячейка цела 95% в настоящем пространстве и 98% на рисунке, ближайший сосед — свой тип в 100% случаев и там и там; общие расстояния переданы на 0.63, радиус ячейки на +0.45 — то есть разнесённость и рыхлость по картинке читать нельзя.

Что видно: служебные ячейки самые крупные и плотные (the — 60 вхождений, your 47, of 39, to 36); пунктуация сбивается в свою область; смысловые ячейки мельче; сток стоит наособицу; однократные токены заполняют середину, а не край.

Ячейки всех токенов ($k \geq 2$), текст 50: 40 типов, центр — крестом, спицы — принадлежность ячейке



t-SNE по настоящим расстояниям, перплексия 30. Ячейки держатся: свой тип среди $k-1$ ближайших соседей в 95% случаев в настоящем пространстве и 98% на рисунке; ближайший сосед свой — 100% и 100%.
Чего по картинке читать нельзя: насколько ячейки разнесены (общие расстояния переданы на 0.63 — t-SNE преувеличивает разрывы) и какая ячейка рыхлее (радиус +0.45). Разнесённость держится на числах: зазор 1.64 радиуса, раздел 5.
Однократные слова — это ячейки из одной точки: своего центра у них нет, ближайший сосед всегда чужой.

40 ячеек и 45 однократных токенов одного документа, 777 точек. [cells_projection.py, CLASSES=all MIN_K=2 N_TYPES=40]

6. Перемешивание слов

мешок токенов цел, контекст уничтожен


Идеальный контроль: перемешивание сохраняет мешок токенов (уцелел на 97.1%), уничтожая только контекст. Значит все лексические статистики — доля хапаксов, кратности, состав по классам — неизменны по построению.

Ячейки раздуваются, каркас стоит:

радиус ячейки, смысловые	+16.8%	
зазор, смысловые	-18.2%	(1.64 -> 1.34)
одиночка -> ближайший центр	-2.1%	
центр -> ближайший центр	+2.1%	
число центров / одиночек	+2.3% / -0.7%	(незначимо)

То есть контекст собирает вхождения слова, а не размазывает: в связном тексте слово употреблено в согласованных ролях. Форма ячейки тоже теряется — participation ratio ниже случайного набора того же размера (5.48 против 8.37 при $k = 12$), а после перемешивания подтягивается к нему (+20%).

Полосы при этом: крупная -13.4%, мелкая +39.6%. Синтетика — 94 одиночки и 31 комок вокруг гауссовых центров, ничего лексического — воспроизводит знаки: -6.1% и +32.4%. Механизм геометрический: раздутые ячейки заполняют промежутки между центрами.



Синтетика: меняется только радиус комка, всё остальное фиксировано. Крупная убывает монотонно, мелкая растёт. Диапазон обрезан на 0.32: дальше комки сливаются и устройство «центры + ячейки» распадается.

[synthetic_inflate.py]

7. Что закрыто и что осталось

полосы разошлись и по проверяемости тоже

Два предиктора — доля одиночек и радиус ячейки — почти независимы ($r = 0.18$). Их совместный R^2 , и потолок, который ставит шум одного зерна (7–8%) при разбросе полос 13–16%:

	оба + длина	потолок R^2	доля потолка
средняя	0.666	0.81	82%
мелкая	0.458	0.66	70%
крупная	0.210	0.73	29%



Средняя полоса по существу закрыта: тремя числами объясняется 82% объяснимого, и как признак она вряд ли несёт что-то сверх доли одиночек, радиуса и длины.

Крупная — 29%, и это самое интересное место. Одиночество необходимо, но длину черешка одиночки лексика не объясняет. Это ровно механизм «локальной уместности редкого токена» из HYPOTHESES.md, и он не выражен ни в одном нашем признаке.

Осталось открытым:

- Половина падения крупной полосы при перемешивании: –13.4% в реальности против –6.1% у синтетики.
- Что крупная полоса видит сверх доли одиночек.
- Насыщенные служебные кластеры — не подходили.
- Одинакова ли размерность каркаса для разных классов токенов: каркас мерили целиком.
- Переживает ли калибровка рост выборки. Доля токенов без двойника падает как $n^{-0.287}$, а крупная полоса питается ими. На COLING не проверяется: при $L = 500$ годится 41 текст из 650.

Проверено и не подтвердилось: гипотеза, что дрейф состава по сетке подгонки смещает наклон $\log S(n)$. Кривизна есть, но на равномерной синтетике без токенов такая же.



Листья и хапаксы вдоль масштаба, сведённые к полосам. По листьям полосы различаются в 1.1 раза, по хапаксам — в 19. [leaf_edges.py]